第四节课习题作业答案

算法理论题

题目1（distributional RL）

价值函数是强化学习算法中的核心概念。某一个策略下计算获得的一个状态的价值或一个动作状态对的价值，衡量了当前策略所能获取的最大累计回报的相对大小，因而对策略的价值函数进行优化，是学习获得更优策略的一种方式。优化价值函数的方法是通过使用贝尔曼最优方程 (Bellman Optimality Equation) 来进行价值函数的更新：

$$Q^*(s,a) = r(s,a) + \gamma \max_{a' \in \mathcal{A}} Q^*(s',a')$$

上式中，$Q^*(s,a)$ 为理论中的最优策略下，该状态 s 和动作 a 对应的价值函数，$r(s,a)$ 为这个状态动作对带来的回报。由于在实际操作中，我们刚开始只有某个一般策略 π 下的价值函数 $Q(s,a)$，即在该一般策略下，收集到的轨迹下游所有累计回报的期望，那么为了求得最优价值函数 $Q^*(s,a)$，我们需要使用算子来逐步更新我们对价值函数的建模估计。贝尔曼最优算子 $\mathcal{T}$ 的形式为：

$$\mathcal{T}Q(s,a) = \mathbb{E}[r(s,a)] + \gamma \mathbb{E}_{\pi}[\max_{a' \in \mathcal{A}} Q(s',a')]$$

然而，由于环境中随机性的广泛存在（比如随机时刻风速的大小，会影响马拉松运动员的相对完成时间，而与运动员的比赛策略与个人能力无关），或是某些独立于动作与状态的随机的意外事件的发生（比如突然出现的自然灾害，会影响农作物的收成的相对大小，而与农业耕种的一整年的策略无关），这意味着每一个状态动作对的回报，$r(s,a)$，可能是一个随机数值。因此，在某个策略 π 下所生成的轨迹所有累计回报 $Z(s,a)$，也会成为一个概率分布：

$$Z(s_t,a_t) = \sum_{i=0}^{end} \gamma^i r(s_{t+i}, a_{t+i})$$

上式中，下一时刻的状态满足状态转移概率的分布，即 $s_{t+i} \sim P(\cdot|s_{t+i-1}, a_{t+i-1})$，下一时刻的动作遵循当前的策略下动作的概率分布，$a_{t+i} \sim \pi(\cdot|s_{t+i-1})$，累计回报将求和至所有的终止状态，记所有终止状态对应时刻的 i 为 end。

所以我们的强化学习算法也就相应地需要转变为求得这个概率分布上的最优策略。在使用该优化算子进行策略提升时，其实质形式变为：

$$\mathcal{T}Z(s,a) = r(s,a) + \gamma Z(s',a')$$

其中，$s' \sim p(\cdot|s,a)$，$a' \sim \pi(\cdot|s')$

具体来说当价值函数成为一个分布（distribution），相比于一个数（scalar），在更新前后会发生什么潜在的影响，我们可以使用下面一个例子来形象化说明这一点：

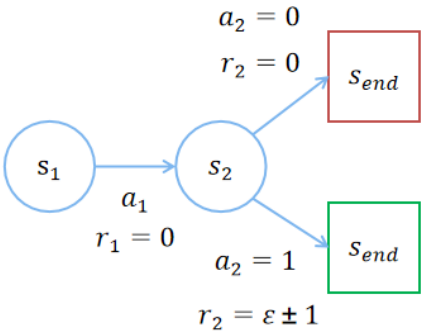

对于一个由 $s_1 \rightarrow s_2 \rightarrow s_{\text{end}}$ 构成的MDP。在状态 s_1 时仅有 a_1 一个动作可以选择，奖励为 $r_1 = 0$ 。在状态 s_2 时有 $a_2 = 0$ 和 $a_2 = 1$ 两个动作可以选择，奖励分别为 $r_2 = 0$ （为确定性的数值）和 $r_2 = \epsilon \pm 1$ （为随机数，且事件发生的概率均等），其中 $\epsilon \geq 0$ 。

1、请计算理论上的最优动作价值函数的数值 $Q(s_1, a_1)$ ， $Q(s_2, a_2 = 0)$ ， $Q(s_2, a_2 = 1)$ 与最优动作价值函数的分布 $Z(s_1, a_1)$ ， $Z(s_2, a_2 = 0)$ ， $Z(s_2, a_2 = 1)$ ，为了简化计算，令 $\gamma = 1$

（示例：比如 $Q(s_2, a_2 = 1) = \mathbb{E}(r(s_2, a_2)) + 0 = \epsilon$ ， $Z(s_2, a_2 = 1) = r(s_2, a_2) + 0 = \epsilon \pm 1$ ）

2、假如当前策略的动作价值函数分布为 $Z(s_1, a_1) = \epsilon \pm 1$ ， $Z(s_2, a_2 = 0) = 0$ ， $Z(s_2, a_2 = 1) = -\epsilon \pm 1$ 。

i) 请计算使用贝尔曼最优算子后，目标动作价值函数的分布， $\mathcal{T}Z(s_1, a_1)$ ， $\mathcal{T}Z(s_2, a_2 = 0)$ ， $\mathcal{T}Z(s_2, a_2 = 1)$ 。

（示例：比如 $\mathcal{T}Z(s_2, a_2 = 1) = r(s_2, a_2 = 1) + 0 = \epsilon \pm 1$ ）

ii) 衡量两个概率分布之间的距离的测度方法有很多，其中之一为Wasserstein Metric [1]。假如标记 p 阶Wasserstein Metric 为 W_p ，其表达式如下：

$$W_p(\mu, \nu) = (\inf_{\gamma \in \Gamma(\mu, \nu)} \mathbb{E}_{(x,y)\sim\gamma} d(x, y)^p)^{\frac{1}{p}}$$

请计算使用贝尔曼最优算子前后，当前策略的动作价值函数与最优策略的动作价值函数的 1 阶 Wasserstein Metric。比较并讨论两者的差异，然后尝试分析这种差异的影响。

答案：

1.本题旨在熟悉价值函数的分布的计算方法。

根据贝尔曼算子，代入计算可得各个动作状态对的价值函数：

$$Q(s_2, a_2 = 1) = \mathbb{E}(r(s_2, a_2 = 1)) + 0 = \epsilon$$

$$Q(s_2, a_2 = 0) = 0$$

$$Q(s_1, a_1) = \mathbb{E}(r(s_1, a_1)) + \max_{a_2 \in 0,1} Q(s_2, a_2) = \epsilon$$

对于这个简单环境，我们容易看出各个状态下的最优动作，合起来即为最优策略，其价值函数为：

$$Z(s_2, a_2 = 1) = r(s_2, a_2 = 1) + 0 = \epsilon \pm 1$$

$$Z(s_2, a_2 = 0) = 0$$

$$Z(s_1, a_1) = r(s_1, a_1) + r(s_2, a_2 = 1) = \epsilon \pm 1$$

2.本题旨在了解贝尔曼算子用于分布式价值函数时的影响。

i)

直接代入贝尔曼最优算子，可以得到：

$$\mathcal{T}Z(s_2, a_2 = 0) = 0$$

$$\mathcal{T}Z(s_2, a_2 = 1) = r(s_2, a_2 = 1) + 0 = \epsilon \pm 1$$

$$\mathcal{T}Z(s_1, a_1) = r(s_1, a_1) + r(s_2, a_2 = 0) = 0$$

ii)

从上述结果可知，最优策略对应的动作价值为：

$$Z^*(s_1, a_1) = \epsilon \pm 1$$

$$Z^*(s_2, a_2 = 0) = 0$$

$$Z^*(s_2, a_2 = 1) = \epsilon \pm 1$$

已知更新前策略的动作价值为：

$$Z(s_1, a_1) = \epsilon \pm 1$$

$$Z(s_2, a_2 = 0) = 0$$

$$Z(s_2, a_2 = 1) = -\epsilon \pm 1$$

而当前策略的价值为

$$\mathcal{T}Z(s_1, a_1) = 0$$

$$\mathcal{T}Z(s_2, a_2 = 0) = 0$$

$$\mathcal{T}Z(s_2, a_2 = 1) = \epsilon \pm 1$$

可以计算更新前后各个动作状态对应的价值的 1 阶 Wasserstein Metric为：

$$[W_1(Z^*(s_1, a_1), Z(s_1, a_1)), W_1(Z^*(s_2, a_2 = 0), Z(s_2, a_2 = 0)), W_1(Z^*(s_2, a_2 = 1), Z(s_2, a_2 = 1))] = [0, 0, 2\epsilon]$$

$$[W_1(\mathcal{T}Z(s_1, a_1), Z(s_1, a_1)), W_1(\mathcal{T}Z(s_2, a_2 = 0), Z(s_2, a_2 = 0)), W_1(\mathcal{T}Z(s_2, a_2 = 1), Z(s_2, a_2 = 1))] = [\frac{1}{2}|1 - \epsilon| + \frac{1}{2}|1 + \epsilon|, 0, 0]$$

因为 $\frac{1}{2}|1-\epsilon|+\frac{1}{2}|1+\epsilon|>2\epsilon$，所以我们可以发现，使用贝尔曼最优算子更新之后，**当前策略的价值函数**距离**最优策略的价值函数**之间的距离**变远**了。本质上，这是由于对于随机性较大的价值函数分布，贝尔曼最优算子 $\mathcal{T}$ 并不是一个收缩算子(contraction functor)，因此这种现象会导致强化学习算法在训练过程中可能的收敛性问题，比如最优的价值函数可能并不存在一个定值解，详情可以阅读文献《A Distributional Perspective on Reinforcement Learning》。

题目2（更高级的探索算法：Upper Confidence Bound）

电影《流浪地球2》中，移山计划的验证项目建设过程中，月球太空设备仓库新到了一批来自两家制造厂商的同一款处理器芯片，不过由于两家厂商的工艺水平不同，在遭受一次太阳风暴高能粒子袭击后，两种芯片有少量被损坏，且比例不太相同，但是难以检测。有一天机器狗笨笨接到新任务，需要安装一定数量芯片到对应数量的工作机器上，希望那些机器可以被顺利启动并工作的比例越高越好。笨笨一次只能选择来自一个厂商的芯片（可以记为决策动作 $a=0$ 与 $a=1$），并安装到一台机器上，并尝试启动它（启动成功时，可以记为奖励 $r=1$，启动失败记为奖励 $r=0$）。最早设计决策算法的工程师为了赶DDL交差，只给笨笨写了 $\epsilon-\text{greedy}$ 算法，现在我们需要一种更高级的探索算法UCB（Upper Confidence Bound）[2]，帮助笨笨更好地完成这个工作。

请参考下文中的提示，证明机械狗笨笨需要采用的UCB算法的数学形式为：

$$a_t=\arg\max_a[Q_t(a)+c\sqrt{\frac{\log t}{N_t(a)}}]$$

其中 t 为第 t 次安装测试。$N_t(a)$ 为累计至第 $t-1$ 次安装时，选择 a 厂商的次数。$Q_t(a)$ 为累计至第 $t-1$ 次安装时的平均动作价值。c 为平衡探索效益和利用效益之间的系数。

提示：

i)

一般来说，最优算法的设计目标是为了最大化累计的回报，即：

$$\max\sum_t r_t(s_t,a)$$

我们可以把使用动作 a 的平均奖励记为 $Q(a)$：

$$Q(a)=\frac{1}{N}\sum_{i=1}^{N}r_i(s_i,a)$$

但是由于对环境信息的未知，智能体需要做探索性的尝试来获取更多信息，并利用已有信息决策，取得更优的奖励。不过由于客观条件的限制，在有限的时空内，探索和利用往往是互斥的，如何平衡多少程度的探索和多少程度的利用，会最终影响决策算法的最终表现。因此，如何用数学方法平衡探索（Exploration）和利用（Exploitation），是各类算法的核心区别。

对于常见的 $\epsilon-\text{greedy}$ 算法，它平衡探索和利用的方式是使用一个小概率 ϵ 做随机探索，再用 $1-\epsilon$ 的概率来做最大化当前效益的利用。但是很明显，这种简单粗暴的方式存在问题，它忽视了探索过程带来的信息，我们可以设计算法利用这些信息从而逐渐降低不确定性，但 $\epsilon-\text{greedy}$ 算法因为设计上过于简单，并不会有效地利用这些信息。

而UCB方法使用了**“保持最乐观态度去面对未来的不确定性”的原则**，来平衡探索和利用这两者。

也就是说，在 UCB 策略中，对于任意 t 时刻，智能体会对某个动作的平均奖励做一个比较乐观的估计，可以记为 $\tilde{Q}_t(a)$，真实的平均奖励记为 $Q_t(a)$，这个乐观的估计是真实值的一个上界：

$$\tilde{Q}_t(a) \geq Q_t(a)$$

UCB方法的原则，是要去尽可能地信任这个上界，将它作为选择动作的依据，即选择所有动作中，乐观估计的上界最大的动作，作为本次决策的结果：

$$a_t = \arg\max_a [\tilde{Q}_t(a)]$$

需要注意到的是，在每个第 t 时刻，这意味着已经具备前 $t-1$ 时刻所有交互的信息。所以可以根据这些信息，来估计这个乐观的上界的范围。

所以原问题等价于，论述为什么公式 $\tilde{Q}_t(a) = Q_t(a) + c\sqrt{\frac{\log t}{N_t(a)}}$ 是一种乐观形式的上界。

ii)

霍夫丁不等式 (Hoeffding's inequality)：

如果 Z 为一系列独立同分布且有界的随机数，$Z_i \in [a,b]$，$-\infty < a \leq b < +\infty$，那么对于所有的非负实数，$\delta \geq 0$，都有如下不等式成立：

$$P(\frac{1}{n}[\sum_{i=1}^{n}(Z_i - \mathbb{E}[Z_i])] \geq \delta]) \leq \exp(-\frac{2n\delta^2}{(b-a)^2})$$

$$P(\frac{1}{n}[\sum_{i=1}^{n}(Z_i - \mathbb{E}[Z_i])] \leq -\delta]) \leq \exp(-\frac{2n\delta^2}{(b-a)^2})$$

答案：

已知，在该问题中，随机收益的数值为 $r=0$ 或 $r=1$，根据 Hoeffding's inequality，有：

$$P(\frac{1}{n}[\sum_{i=1}^{n}(r_i - \mathbb{E}[r_i])] \geq \delta]) \leq \exp(-\frac{2n\delta^2}{(1-0)^2}) = \exp(-2n\delta^2)$$

$$P(\frac{1}{n}[\sum_{i=1}^{n}(r_i - \mathbb{E}[r_i])] \leq -\delta]) \leq \exp(-\frac{2n\delta^2}{(1-0)^2}) = \exp(-2n\delta^2)$$

于是有：

$$P(-\delta \leq \frac{1}{n}[\sum_{i=1}^{n}(r_i - \mathbb{E}[r_i])] \leq \delta) \geq 1 - 2\exp(-2n\delta^2)$$

- 假如我们希望平均收益的上界是可信的，即上式概率可以按照时间收敛至概率 1 ，即 $-2n\delta^2$ 要随时间趋向 $-\infty$
- 假如我们还希望平均收益的上界可以按时间逐渐收紧，即 δ 需要按时间趋向于 0
- 但是，次数 n 会随时间线性趋向 $+\infty$ ，所以为了同时满足上述条件， $1/\delta^2$ 在数值上需要弱于一阶线性

在这里，我们可以让 $\delta = c\sqrt{\frac{\log\ t}{n}}$ 并代入上式，就得到UCB策略的公式：

$$\tilde{Q}_t(a) = Q_t(a) + c\sqrt{\frac{\log t}{N_t(a)}}$$

并且从表达式中可以得知， c 越大，探索性越强，上界越宽，但概率将按照 $1 - \frac{2}{t^{2c^2}}$ 的速率越快收敛。

另外，除了 $\epsilon - \text{greedy}$ 算法，UCB方法（Upper Confidence Bound）之外，常见的平衡探索与利用的算法有很多，比如汤普森采样法（Thompson sampling method）[3] 等等，大家可以查询相关文献和教材，形成对这些方法具体性质和数学形式的认识，会对未来更好地设计新算法大有裨益。

此外，OpenDILab 整理并维护了有关强化学习算法中的探索性方法为主题的文献资料库，欢迎对此类主题感兴趣的小伙伴访问以下地址，**Awesome Exploration Methods in Reinforcement Learning** [4]，希望它能对读者们的算法修炼之路起到些许帮助~

代码实践题

题目1（奖励模型的训练实践）

在许多现实生活中决策任务里，往往许多问题都是一些稀疏奖励的问题，在解决问题的过程中，长期无法获得激励和回报，这会给强化学习算法的寻优探索和顺利训练带来一定的挑战。基于好奇心探索的内在奖励模型，是帮助强化学习算法是解决这个问题的一种思路。

在论文《Exploration by Random Network Distillation》中，研究者们提出了一种 random network distillation (RND) 方法来辅助探索，激励智能体访问其不熟悉（更新颖）的状态，并期望从这种内在奖励引导的探索中获得更大的潜在收益。

在本题目中，我们将尝试一个简化后的 RND 奖励模型训练实践任务。具体来说，我们收集了Minigrid [5] 环境（具体为“MiniGrid-Empty-8x8-v0”）强化学习训练过程中产生的部分数据，现在请你**尝试**

使用不同超参数设置的 RND 预测网络，用于回归一个固定大小的目标网络的输出，并将预测网络和目标网络的输出的预测差值作为内在探索奖励的大小，观察 Tensorboard 中相关的数据记录结果，分析探索奖励的数值在预测网络各个训练阶段的变化，评估其奖励数值的大小和范围与模型本身的**欠拟合或过拟合**等因素之间的关联。

具体的示例代码如下，只需选择其中不同的超参数配置进行训练，并观察和分析相应表现：

数据下载链接为（包含训练集和验证集）：传送门

下方的代码也可以从官网链接下载：传送门

```python
# pip install minigrid
from typing import Union, Tuple, Dict, List, Optional
from multiprocessing import Process
import multiprocessing as mp
import random
import numpy as np
import torch
import torch.nn as nn
import torch.nn.functional as F
import torch.optim as optim
import minigrid
import gymnasium as gym
from torch.optim.lr_scheduler import ExponentialLR, MultiStepLR
from tensorboardX import SummaryWriter
from minigrid.wrappers import FlatObsWrapper

random.seed(0)
np.random.seed(0)
torch.manual_seed(0)
if torch.cuda.is_available():
    device = torch.device("cuda:0")
else:
    device = torch.device("cpu")

train_config = dict(
    train_iter=1024,
    train_data_count=128,
    test_data_count=4096,
)

little_RND_net_config = dict(
    exp_name="little_rnd_network",
    observation_shape=2835,
    hidden_size_list=[32, 16],
```

```
    learning_rate=1e-3,
    batch_size=64,
    update_per_collect=100,
    obs_norm=True,
    obs_norm_clamp_min=-1,
    obs_norm_clamp_max=1,
    reward_mse_ratio=1e5,
)

small_RND_net_config = dict(
    exp_name="small_rnd_network",
    observation_shape=2835,
    hidden_size_list=[64, 64],
    learning_rate=1e-3,
    batch_size=64,
    update_per_collect=100,
    obs_norm=True,
    obs_norm_clamp_min=-1,
    obs_norm_clamp_max=1,
    reward_mse_ratio=1e5,
)

standard_RND_net_config = dict(
    exp_name="standard_rnd_network",
    observation_shape=2835,
    hidden_size_list=[128, 64],
    learning_rate=1e-3,
    batch_size=64,
    update_per_collect=100,
    obs_norm=True,
    obs_norm_clamp_min=-1,
    obs_norm_clamp_max=1,
    reward_mse_ratio=1e5,
)

large_RND_net_config = dict(
    exp_name="large_RND_network",
    observation_shape=2835,
    hidden_size_list=[256, 256],
    learning_rate=1e-3,
    batch_size=64,
    update_per_collect=100,
    obs_norm=True,
    obs_norm_clamp_min=-1,
    obs_norm_clamp_max=1,
    reward_mse_ratio=1e5,
)
```

```python

very_large_RND_net_config = dict(
    exp_name="very_large_RND_network",
    observation_shape=2835,
    hidden_size_list=[512, 512],
    learning_rate=1e-3,
    batch_size=64,
    update_per_collect=100,
    obs_norm=True,
    obs_norm_clamp_min=-1,
    obs_norm_clamp_max=1,
    reward_mse_ratio=1e5,
)

class FCEncoder(nn.Module):
    def __init__(
            self,
            obs_shape: int,
            hidden_size_list,
            activation: Optional[nn.Module] = nn.ReLU(),
    ) -> None:
        super(FCEncoder, self).__init__()
        self.obs_shape = obs_shape
        self.act = activation
        self.init = nn.Linear(obs_shape, hidden_size_list[0])

        layers = []
        for i in range(len(hidden_size_list) - 1):
            layers.append(nn.Linear(hidden_size_list[i], hidden_size_list[i + 1]
            layers.append(self.act)
        self.main = nn.Sequential(*layers)

    def forward(self, x: torch.Tensor) -> torch.Tensor:
        x = self.act(self.init(x))
        x = self.main(x)
        return x

class RndNetwork(nn.Module):
    def __init__(self, obs_shape: Union[int, list], hidden_size_list: list) -> N
        super(RndNetwork, self).__init__()
        self.target = FCEncoder(obs_shape, hidden_size_list)
        self.predictor = FCEncoder(obs_shape, hidden_size_list)

        for param in self.target.parameters():
            param.requires_grad = False

    def forward(self, obs: torch.Tensor) -> Tuple[torch.Tensor, torch.Tensor]:
```

```
129         predict_feature = self.predictor(obs)
130         with torch.no_grad():
131             target_feature = self.target(obs)
132         return predict_feature, target_feature
133 
134 class RunningMeanStd(object):
135     def __init__(self, epsilon=1e-4, shape=(), device=torch.device('cpu')):
136         self._epsilon = epsilon
137         self._shape = shape
138         self._device = device
139         self.reset()
140 
141     def update(self, x):
142         batch_mean = np.mean(x, axis=0)
143         batch_var = np.var(x, axis=0)
144         batch_count = x.shape[0]
145 
146         new_count = batch_count + self._count
147         mean_delta = batch_mean - self._mean
148         new_mean = self._mean + mean_delta * batch_count / new_count
149         # this method for calculating new variable might be numerically unstable
150         m_a = self._var * self._count
151         m_b = batch_var * batch_count
152         m2 = m_a + m_b + np.square(mean_delta) * self._count * batch_count / new
153         new_var = m2 / new_count
154         self._mean = new_mean
155         self._var = new_var
156         self._count = new_count
157 
158     def reset(self):
159         if len(self._shape) > 0:
160             self._mean = np.zeros(self._shape, 'float32')
161             self._var = np.ones(self._shape, 'float32')
162         else:
163             self._mean, self._var = 0., 1.
164         self._count = self._epsilon
165 
166     @property
167     def mean(self) -> np.ndarray:
168         if np.isscalar(self._mean):
169             return self._mean
170         else:
171             return torch.FloatTensor(self._mean).to(self._device)
172 
173     @property
174     def std(self) -> np.ndarray:
175         std = np.sqrt(self._var + 1e-8)
```

```
176         if np.isscalar(std):
177             return std
178         else:
179             return torch.FloatTensor(std).to(self._device)
180 
181 class RndRewardModel():
182 
183     def __init__(self, config) -> None:  # noqa
184         super(RndRewardModel, self).__init__()
185         self.cfg = config
186 
187         self.tb_logger = SummaryWriter(config["exp_name"])
188         self.reward_model = RndNetwork(
189             obs_shape=config["observation_shape"], hidden_size_list=config["hidd
190         ).to(device)
191 
192         self.opt = optim.Adam(self.reward_model.predictor.parameters(), config["
193         self.scheduler = ExponentialLR(self.opt, gamma=0.997)
194 
195         self.estimate_cnt_rnd = 0
196         if self.cfg["obs_norm"]:
197             self._running_mean_std_rnd_obs = RunningMeanStd(epsilon=1e-4, device
198 
199     def __del__(self):
200         self.tb_logger.flush()
201         self.tb_logger.close()
202 
203     def train(self, data) -> None:
204         for _ in range(self.cfg["update_per_collect"]):
205             train_data: list = random.sample(data, self.cfg["batch_size"])
206             train_data: torch.Tensor = torch.stack(train_data).to(device)
207             if self.cfg["obs_norm"]:
208                 # Note: observation normalization: transform obs to mean 0, std
209                 self._running_mean_std_rnd_obs.update(train_data.cpu().numpy())
210                 train_data = (train_data - self._running_mean_std_rnd_obs.mean)
211                 train_data = torch.clamp(
212                     train_data, min=self.cfg["obs_norm_clamp_min"], max=self.cfg
213                 )
214 
215             predict_feature, target_feature = self.reward_model(train_data)
216             loss = F.mse_loss(predict_feature, target_feature.detach())
217             self.opt.zero_grad()
218             loss.backward()
219             self.opt.step()
220         self.scheduler.step()
221 
222     def estimate(self, data: list) -> List[Dict]:
```

```
        """
        estimate the rnd intrinsic reward
        """

        obs = torch.stack(data).to(device)
        if self.cfg["obs_norm"]:
            # Note: observation normalization: transform obs to mean 0, std 1
            obs = (obs - self._running_mean_std_rnd_obs.mean) / self._running_me
            obs = torch.clamp(obs, min=self.cfg["obs_norm_clamp_min"], max=self.

        with torch.no_grad():
            self.estimate_cnt_rnd += 1
            predict_feature, target_feature = self.reward_model(obs)
            mse = F.mse_loss(predict_feature, target_feature, reduction='none').
            self.tb_logger.add_scalar('rnd_reward/mse', mse.cpu().numpy().mean()

            # Note: according to the min-max normalization, transform rnd reward
            rnd_reward = mse * self.cfg["reward_mse_ratio"]  #(mse - mse.min())

            self.tb_logger.add_scalar('rnd_reward/rnd_reward_max', rnd_reward.ma
            self.tb_logger.add_scalar('rnd_reward/rnd_reward_mean', rnd_reward.m
            self.tb_logger.add_scalar('rnd_reward/rnd_reward_min', rnd_reward.mi

            rnd_reward = torch.chunk(rnd_reward, rnd_reward.shape[0], dim=0)

def training(config, train_data, test_data):
    rnd_reward_model = RndRewardModel(config=config)
    for i in range(train_config["train_iter"]):
        rnd_reward_model.train([torch.Tensor(item["last_observation"]) for item
        rnd_reward_model.estimate([torch.Tensor(item["last_observation"]) for it

def main():
    env = gym.make("MiniGrid-Empty-8x8-v0")
    env_obs = FlatObsWrapper(env)

    train_data = []
    test_data = []

    for i in range(train_config["train_iter"]):

        train_data_per_iter = []

        while len(train_data_per_iter) < train_config["train_data_count"]:
            last_observation, _ = env_obs.reset()
            terminated = False
            while terminated != True and len(train_data_per_iter) < train_config
                action = env_obs.action_space.sample()
```

```
                observation, reward, terminated, truncated, info = env_obs.step(
                train_data_per_iter.append(
                    {
                        "last_observation": last_observation,
                        "action": action,
                        "reward": reward,
                        "observation": observation
                    }
                )
                last_observation = observation
            env_obs.close()

        train_data.append(train_data_per_iter)

    while len(test_data) < train_config["test_data_count"]:
        last_observation, _ = env_obs.reset()
        terminated = False
        while terminated != True and len(train_data_per_iter) < train_config["te
            action = env_obs.action_space.sample()
            observation, reward, terminated, truncated, info = env_obs.step(acti
            test_data.append(
                {
                    "last_observation": last_observation,
                    "action": action,
                    "reward": reward,
                    "observation": observation
                }
            )
            last_observation = observation
        env_obs.close()

    p0 = Process(target=training, args=(little_RND_net_config, train_data, test_
    p0.start()

    p1 = Process(target=training, args=(small_RND_net_config, train_data, test_d
    p1.start()

    p2 = Process(target=training, args=(standard_RND_net_config, train_data, tes
    p2.start()

    p3 = Process(target=training, args=(large_RND_net_config, train_data, test_d
    p3.start()

    p4 = Process(target=training, args=(very_large_RND_net_config, train_data, t
    p4.start()

    p0.join()
```

```
    p1.join()
    p2.join()
    p3.join()
    p4.join()

if __name__ == "__main__":
    mp.set_start_method('spawn')
    main()
```

答案：

1、

在实验中，我们使用了随机生成的环境数据作为训练集，并使用另一批独立随机生成的环境数据作为验证集，来评估示例代码中预设的5种不同大小的 RND 网络，在训练过程中各个阶段得到的 RND intrinsic reward 的相关统计量（最大值，最小值，平均值）的变化，如下所示 (网络尺寸从小到大依次为，灰、青、红、黄、紫)：

RND网络 reward 最大值，最小值，平均值分布图

从中可以看到，使用较小的网络，会使得 RND 网络得到的 reward 的最小值较大，即 RND 中预测误差的最小值依然在一个较高的范围，这是由于模型参数量不够，使得这组实验出现了欠拟合的状况。这

会使得 RND 网络产生的内在 reward 存在偏差，即受到欠拟合导致的拟合误差的影响，从而会对 RL 训练产生负面影响。使用较大网络和适中大小的网络，都可以看到在训练后期，有效地拟合了部分数值，给出了较低的 reward 最小值。但从 reward 的平均值中看出，它们同时也保持了一定程度的探索性。

2、

在稍后的实验中，我们依然使用了随机生成的环境数据作为训练集，但是是在同一批训练数据上添加一定量噪音扰动作为验证集，用于分析示例代码中预设的5种不同大小的 RND 网络对输入扰动的敏感程度，具体实验效果如下图所示 (网络尺寸从小到大依次为，灰、青、红、黄、紫)：

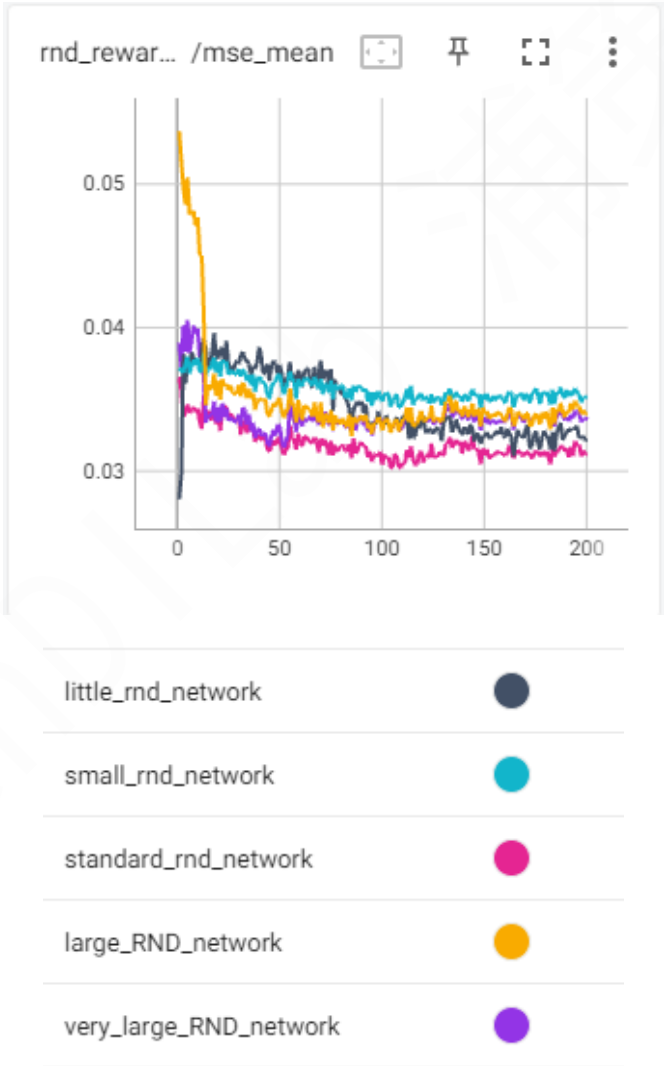

RND网络 MSE 分布图

从中可以发现，相比于标准大小的网络，使用较大网络的模型对输入的局部扰动非常敏感，这意味着这些模型可能在训练的后期出现了一定程度的过拟合。这对 RL 训练也会带来一些麻烦，如果因为 RND 网络在局部的过拟合，会使得在此处区域给出不合理的 reward 估计。

总结来说，基于上述探索实验和相关分析，我们可以得到一个经验性结论：对于具体的决策问题，需要根据其实际的状态空间的大小和数据分布的特点，拟定合适的 RND 网络结构和训练优化器。

题目2（应用实践）

在课程第四讲（解密稀疏奖励空间）几个应用中任选一个

- minigrid 迷宫（奖励的稀疏性）
- metadrive 自动驾驶（奖励的多尺度变化）

根据课程组给出的示例代码，训练得到相应的智能体。最终提交需要上传相关训练代码、日志截图或最终所得的智能体效果视频（replay），具体样式可以参考第四讲的示例 ISSUE。

参考文献

[1] https://en.wikipedia.org/wiki/Wasserstein_metric

[2] Auer P. Using confidence bounds for exploitation-exploration trade-offs[J]. Journal of Machine Learning Research, 2002, 3(Nov): 397-422.

[3] https://en.wikipedia.org/wiki/Thompson_sampling

[4] https://github.com/opendilab/awesome-exploration-rl

[5] https://minigrid.farama.org/environments/minigrid/